Detección de crisis epilépticas mediante análisis de señales EEG

Procesado de Señales Biomédicas

Curso 2024-25

Íñigo Aguirre
Javier Becerril
Paula Crespo
Cristina García
Izaskun Martín
César Ruiz

Índice

1. Introducción 1
2. Datos empleados 3
    2.1 Importación datos y anotaciones 3
    2.2 Visualización temporal y frecuencial 4
3. Filtrado 7
    3.1. Filtrado para eliminar ruido e interferencias 7
    3.2. Pre-procesado de banco de filtros 8
    4. Propuestas de procesados 10
        4.1. Características temporales y umbrales adaptativos 10
        4.2. Características según bandas frecuenciales 11
5. Análisis de resultados 13
    5.1. Métodos 13
    5.2. Resultados obtenidos 14
6. Conclusiones 16
7. Bibliografía 17

1. Introducción

El concepto de crisis epiléptica se refiere a una manifestación clínica transitoria causada por una descarga neuronal anormal, excesiva y sincrónica en el cerebro. Según el artículo *"The Neurobiology of Epilepsy"* de Helen E. Scharfman, estas descargas pueden originarse en diferentes regiones cerebrales y se asocian con alteraciones en el equilibrio entre excitación e inhibición neuronal. Una crisis epiléptica aislada no implica necesariamente epilepsia, que se diagnostica cuando hay dos o más crisis no provocadas o una crisis con alta probabilidad de recurrencia (Scharfman, 2017).

El electroencefalograma (EEG) es una de las herramientas más utilizadas para el diagnóstico de la epilepsia. Mediante esta técnica es posible registrar la actividad eléctrica del córtex cerebral, clasificar el tipo de epilepsia y categorizar eventos neurológicos (López-Trigo et al., 2011).

Sin embargo, el análisis del EEG conlleva ciertos obstáculos a la hora de registrar e identificar los diferentes eventos neurológicos:

1. **Variabilidad interpaciente e intrapaciente:** Las características del EEG difieren significativamente entre pacientes, y entre crisis de un mismo paciente, lo que limita la eficacia de clasificadores generalizados. Esto puede ser debido a:

    - Cambios espontáneos en amplitud (20-300 μV) y frecuencia (0.5-80 Hz) incluso en estado basal.
    - Edad del paciente, ya que los patrones en niños difieren notablemente de adultos. Sin embargo, en nuestro caso esto no representa una fuente de variabilidad, ya que todos los sujetos incluidos en el estudio son niños.
    - Factores anatómicos, debido a que la posición de los electrodos puede verse afectada por surcos corticales o diferencias en el espesor craneal.

2. **Señal no estacionaria:** la señal EEG presenta cambios abruptos en propiedades como la amplitud o frecuencia entre crisis de un mismo paciente o incluso en una misma crisis.

    - Dominio temporal: se observa una transición progresiva (0.5-2 s) desde el estado basal hasta el patrón de crisis epiléptica (Gauthier, 2005). Además, la crisis epiléptica suele comenzar con una desincronización de ritmos fisiológicos, seguida de la aparición súbita de actividad rítmica organizada y finalmente una propagación a otros canales.
    - Dominio frecuencial: distinguimos 3 fases diferentes en función de las frecuencias registradas. En la fase inicial (0-5 s post-inicio) hay ritmo theta (4-7 Hz) en canales focales. En la fase tónica (5-20 s) se produce una expansión a bandas gamma (30-80 Hz). Finalmente, en la clónica se produce una mezcla de frecuencias y modulación en amplitud.

3. **Artefactos:** La señal a analizar se ve interferida por los movimientos oculares (parpadeos 1-3 Hz), actividad muscular (30-300 Hz), artefactos de movimiento (1-3 Hz) o interferencias de la red eléctrica (60 Hz), entre otros.

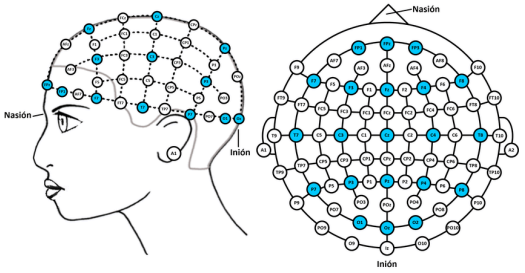
No existe un canal universalmente óptimo para la detección de crisis epilépticas, ya que la elección depende del foco epiléptico de cada paciente. Sin embargo, los canales que aportan más información son los electrodos:

- Temporales: combinaciones como *F7-T7* y *F8-T8* son especialmente útiles en epilepsias del lóbulo temporal.
- Frontales: canales como *FP1-F3* y *FP2-F4* indican epilepsias frontales.
- Occipitales: combinaciones como *P7-O1* y *P8-O2* se emplean en epilepsias occipitales, pero este tipo es poco común y no se va a considerar en el proyecto.

En cuanto al ruido, los electrodos que más se ven afectados suelen ser el *FTP-FT10* por interferencias musculares de masticación y, por otro lado, *FP1-F7 y FP2-F8* contaminados por artefactos de parpadeo.

Figura 1. Distribución electrodos esquema 10-20

Significativos	Ruidosos
F7-T7, F8-T8, FP1-F3, FP-F4	FTP-FT10, FP1-F7, FP2-F8



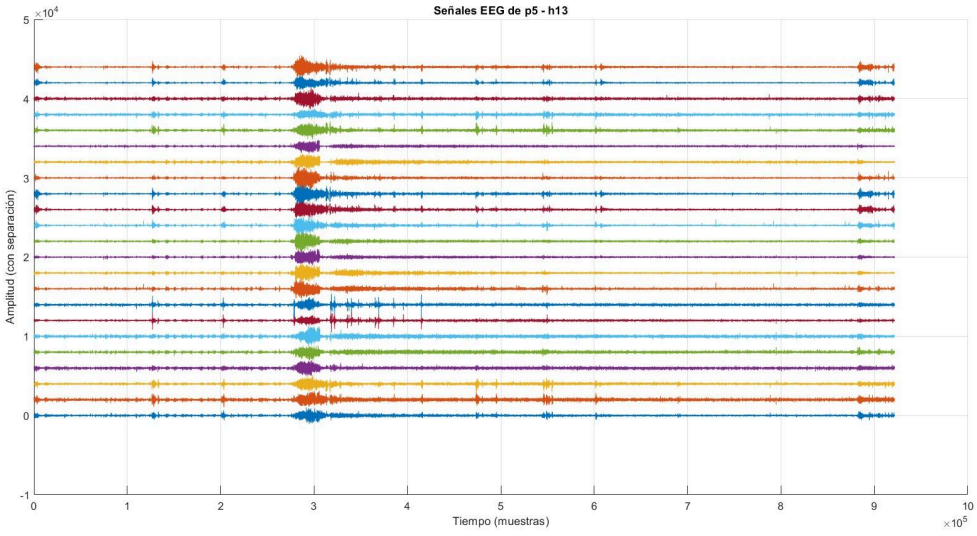
2. Datos empleados

En el siguiente trabajo se utilizó el conjunto de datos CHB-MIT, donde se presenta una colección de señales EEG usadas para la investigación de la epilepsia. En total, se tienen más de 980 horas entre los 22 pacientes disponibles (5 hombres, 17 mujeres, entre 1.5 y 22 años). Para cada paciente, se cuenta con un archivo *summary.txt* que resume datos del paciente y los electrodos empleados en la prueba, archivos *.edf* con los datos EEG crudos y archivos *.seizures* con anotaciones revisadas del inicio y fin de las crisis epilépticas.

2.1 Importación datos y anotaciones

En primer lugar, se procedió a la importación de dichos datos al script de Matlab donde se iban a procesar. Para ello, se creó la función ***cargar_datos_edf2.m***, que toma como entradas la carpeta donde están los datos y un rango de identificadores de pacientes a analizar. Debido a que el análisis de todos los pacientes de manera simultánea resultó ser de una alta carga computacional, se seleccionaron 15 pacientes de manera aleatoria para la extracción y procesado de datos. Dentro de la función, cada archivo .edf se procesa extrayendo el ID del paciente y, para cada archivo de horas, se emplea el *edfread* y *edfinfo* para leer los datos. Esta información se presenta jerárquicamente en dos estructuras de salida: *pacientes*, que contiene los datos temporales de EEG organizados por paciente,hora y canal *(pX.hY.chZ)* y *nombres_canales*, que almacena las etiquetas de cada canal con el correspondiente electrodo al que hacen referencia. Además, esta función muestra mensajes de advertencia si durante la lectura se encuentra algún error del tipo archivo corrupto o canales inválidos.

Figura 1. Representación temporal de los 23 canales para la hora 13 del paciente 5



Después, se obtuvo la información de las crisis epilépticas a partir de las anotaciones de especialistas registradas en los archivos *chbXX-summary.txt*. Estos datos se extrajeron mediante la función ***extraer_crisis_detectada.m*** y, posteriormente, usarlos como el ground-truth para comprobar el funcionamiento de nuestro clasificador. Con este objetivo, se

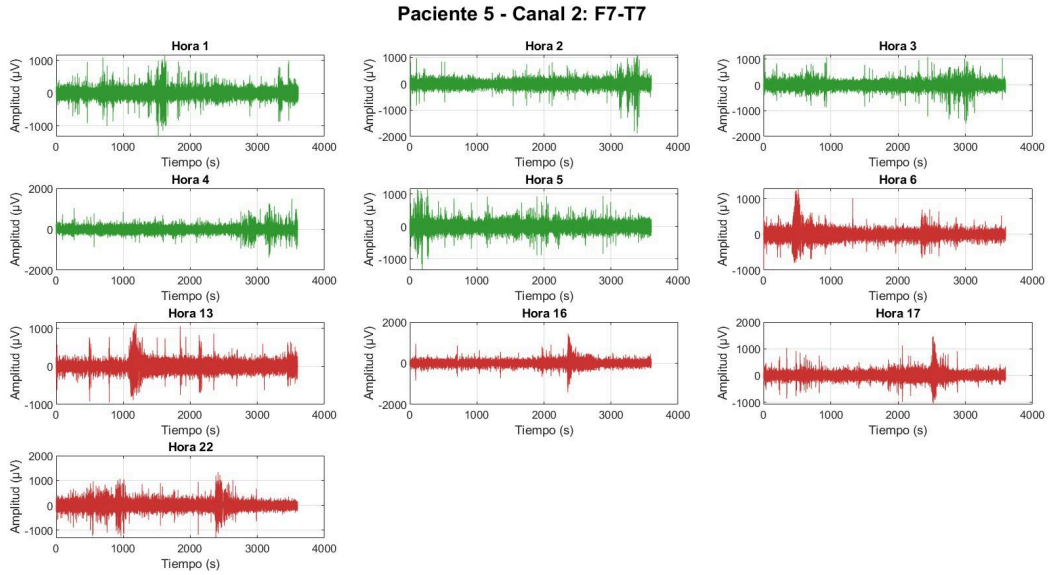
recorren sistemáticamente los archivos de resumen correspondientes al rango de pacientes que se especifique y se crean una estructura jerarquizada que guarde: un booleano sobre si hay crisis o no, el conteo total de crisis por registro y los segundos exactos de inicio y fin de cada episodio epiléptico. Asimismo, para guardar dicha información se creó la función ***exportar_struct_a_excel.m*** donde las matrices de matlab se transforman en cadenas de texto legibles mediante *mat2str* y se registra todo en un archivo excel.

2.2 Visualización temporal y frecuencial

Una vez se extrajeron todos los datos de las señales de EEG, se procedió a graficarlas en el dominio temporal y frecuencial para poder comprender sus características de forma global y, por tanto, sacar posibles conclusiones sobre las necesidades de su filtrado y análisis posterior.

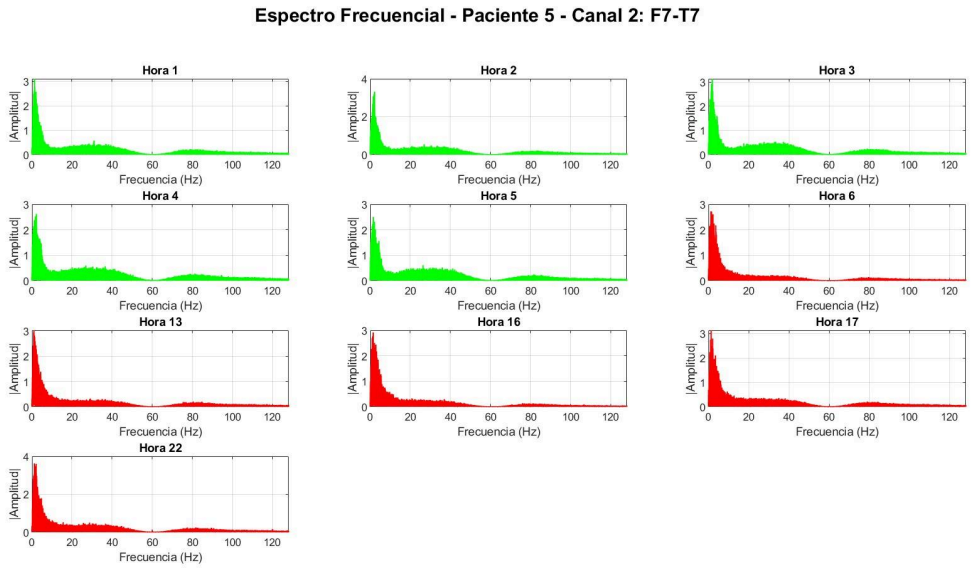
En primer lugar, se visualizaron temporalmente con la función ***graficar_canales_paciente.m*** que recibe como entrada los datos de todas las señales EEG de pacientes con sus etiquetas de electrodos y, por otro lado, la especificación del ID del paciente, las horas y los canales a graficar. Para cada canal escogido se genera un subplot con las distintas horas, graficadas en verde si son horas sanas y en rojo si hay periodos de crisis para posibilitar una identificación visual inmediata. De esta manera, cada figura muestra el identificador del paciente, el número de canal y su correspondiente electrodo anatómico. También, la función valida si los canales solicitados existan y, en caso de error, muestra un listado completo de los canales disponibles con sus etiquetas.

Figura 2. Representación temporal electrodo F7-T7 para paciente 5



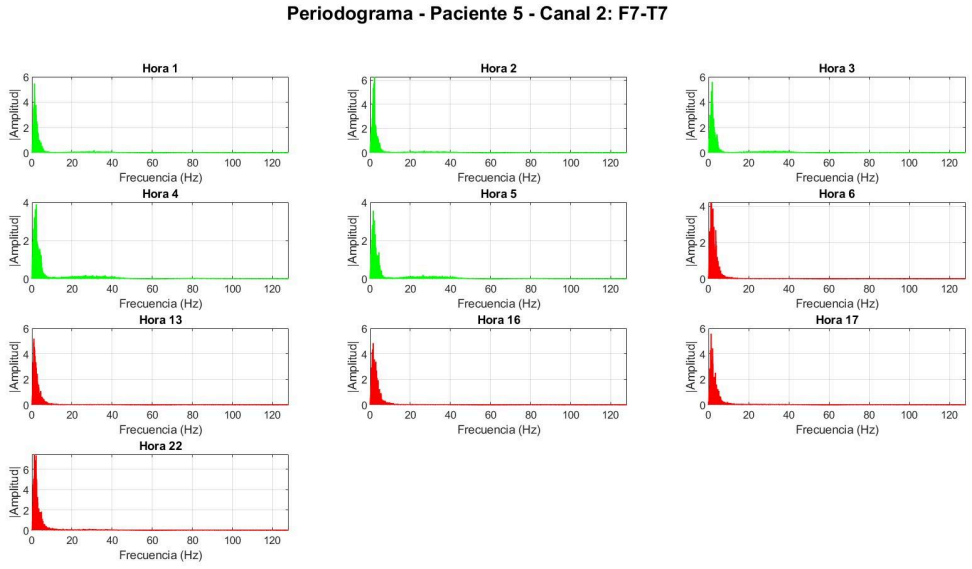
Por otro lado, para la representación frecuencial se diseñó la función ***graficar_fft_paciente.m***, con una estructura similar a la anterior pero representando el espectro frecuencial. Por ello, se empleó la función de *fft* en cada segmento de señal, normalizando la amplitud y ajustando la representación para mostrar sólo hasta la frecuencia de Nyquist (fs/2). En este proceso, se tuvo en cuenta que todas las señales del conjunto de datos empleados contaban con una frecuencia de muestreo de 256 Hz.

Figura 3. Representación frecuencial del electrodo F7-T7 para el paciente 5



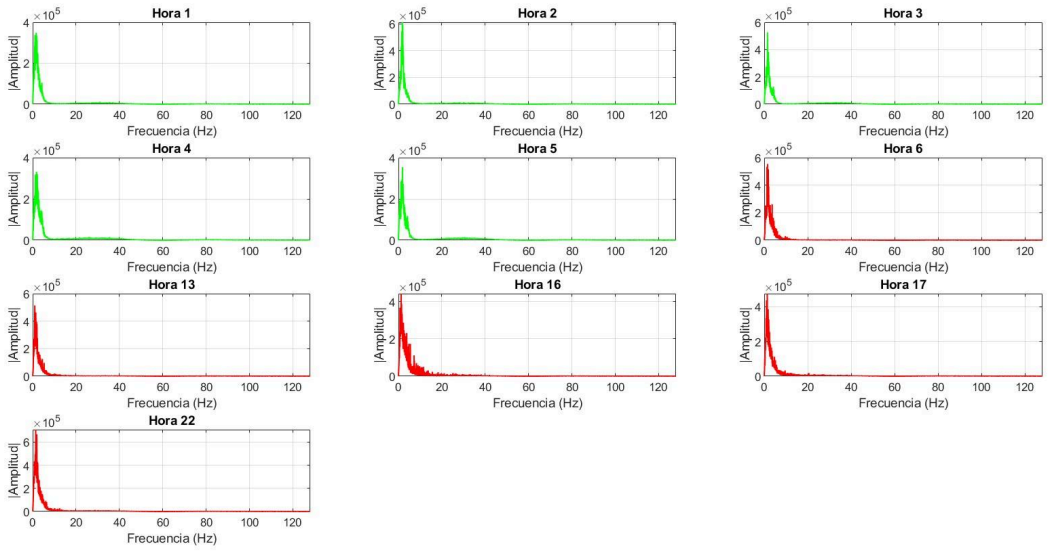
Asimismo, debido a que el EEG tiene cierto grado de no determinismo, puede ser útil la representación del mismo en el dominio frecuencial mediante un periodograma en vez de mediante la FFT. Para la realización de esta tarea nos hemos servido de la función ***graficar_periodograma_paciente.m***.

Figura 4. Representación periodograma del electrodo F7-T7 para el paciente 5



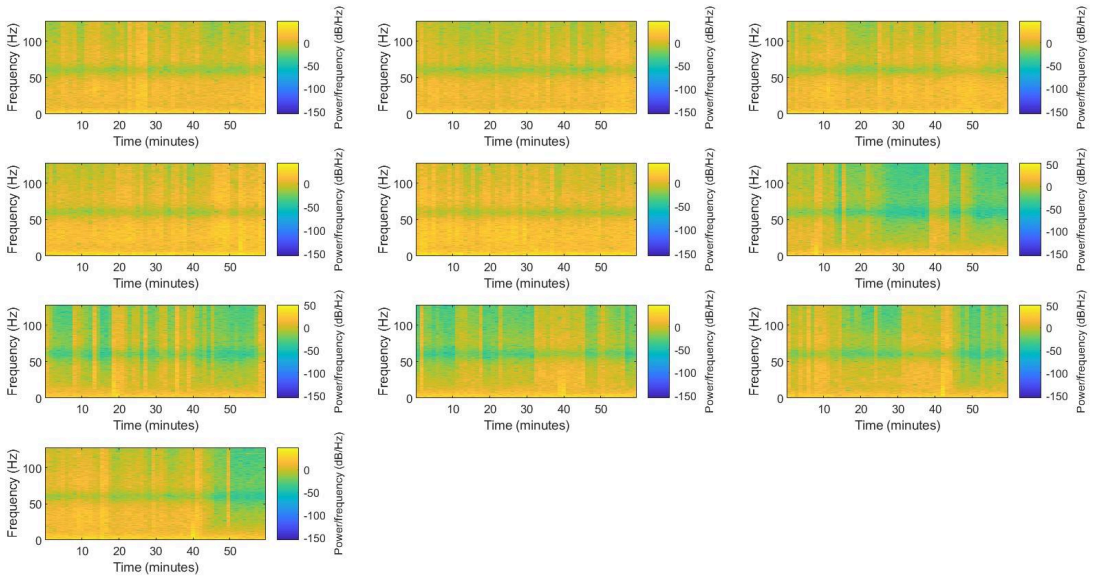
También, en vez de utilizar el método anterior para conseguir el periodograma se puede utilizar el método de Welch (promediado de periodogramas modificados) mediante la función ***graficar_periodograma_welch_paciente.m***.

Figura 5. Representación periodograma Welch del electrodo F7-T7 para el paciente 5



Finalmente, debido a la variación de las características de la señal con el tiempo, pues no es estacionaria, puede ser útil la representación de la señal mediante un espectrograma para poder visualizar los dominios temporal y frecuencial conjuntamente. Esta representación se ha llevado a cabo mediante la función ***graficar_espectrograma_paciente.m***.

Figura 6. Representación del espectrograma del electrodo F7-T7 para el paciente 5



3. Filtrado

En el trabajo se han desarrollado dos métodos para realizar la detección de crisis epilépticas, cada uno de ellos con un script diferente: ***main1.m*** y ***main2.m***. Cada procesado ha necesitado de un filtrado y tratamiento previo de las señales acorde a sus características y, por ello, se han propuesto dos metodologías de filtrado.

3.1. Filtrado para eliminar ruido e interferencias

A la hora de procesar las señales, lo primero es eliminar el ruido y las interferencias. Se comienza eliminando interferencias que no se encuentra en la banda de la señal EEG de superficie mediante un filtro butterworth paso banda de orden 4 con frecuencias de corte 0,5 Hz y 60 Hz implementado empleando la función ***designfilt()***.

Posteriormente, se debe eliminar la interferencia de 60 Hz procedente de la red, lo cual se aborda utilizando un filtro notch centrado en 60 Hz e, igual que el anterior, de orden 4. Estos dos filtros de orden 4 se han implementado conjuntamente en la función ***filtrar_senales.m***, que devuelve una estructura de pacientes, según horas y canales con los resultados filtrados.

Figura 7. Representación temporal del electrodo F7-T7 para el paciente 5 filtrado

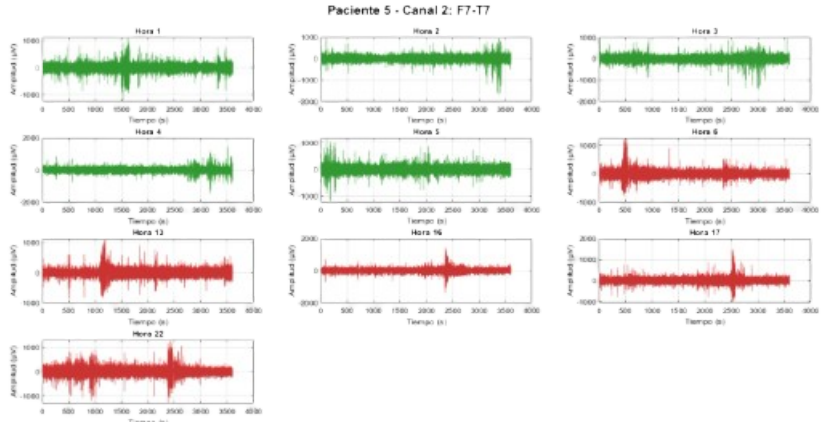
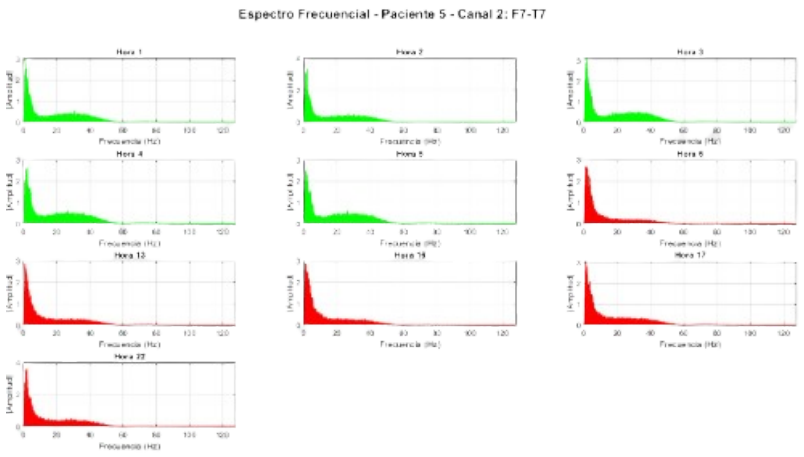


Figura 8. Representación espectral del electrodo F7-T7 para el paciente 5 filtrado



Para separar la señal de la interferencia de red también se podría utilizar filtrado adaptativo sirviendo como referencia una señal senoidal de frecuencia igual a la de la interferencia (60 Hz) y evitando así eliminar posible información que se pueda encontrar a dicha frecuencia. Sin embargo, la mayor parte de la información de la señal EEG se encuentra a menor frecuencia y el filtrado adaptativo supone un periodo de adaptación durante el cual el ruido se elimina en menor medida.

Otros artefactos a eliminar son los artefactos musculares, los artefactos debidos al parpadeo del ojo, los causados por la masticación y los husos del sueño. No obstante, dichos artefactos se solapan con la señal, por lo que el uso de filtros puede suponer la pérdida de la información fuera de la banda de paso de dicho filtro. A esto se suma que la carencia de una señal de referencia para dichos artefactos imposibilita el uso de un filtro adaptativo. En cuanto a los artefactos oculares, éstos se encuentran principalmente entre 0,5 y 8 Hz. Sin embargo, el espectro asociado a estos artefactos también se extiende, en menor medida, a mayores frecuencias. Asimismo, entre 0 y 500 Hz puede haber artefactos de EMG producidos bien por la masticación o bien por la musculatura facial. Finalmente, los husos del sueño se encuentran entre 12 y 14 Hz. Por lo tanto, para evitar la pérdida de información debida al uso de filtros, no hemos eliminado las componentes de estos artefactos que se solapan espectralmente con la señal.

3.2. Pre-procesado de banco de filtros

Para la segunda propuesta de procesado, desarrollada en el archivo ***main2.m***, se hizo un filtrado de las señales previo a la extracción de características para el análisis. Este procesado previo consiste en el filtrado de las señales con una serie de filtros: un filtro Notch a la frecuencia de 60 Hz (en realidad es un filtrado paso bajo porque esas componentes no nos interesan) para eliminar el componente de ruido proveniente de la red.

En nuestra señal aparecen componentes de interferencia de 16 y 32 Hz (para estos sí que recurrimos a filtros Notch debido a que coincide con la banda de frecuencias de interés). Estas se pueden deber al aliasing de los armónicos de 60 Hz (componente de interferencia principal). A continuación, filtramos la señal utilizando un filtro paso bajo hasta 40 Hz ya que es la región frecuencial de interés con información de la señal EEG.

Figura 9. Representación temporal del electrodo F7-T7 para el paciente 5 filtrado

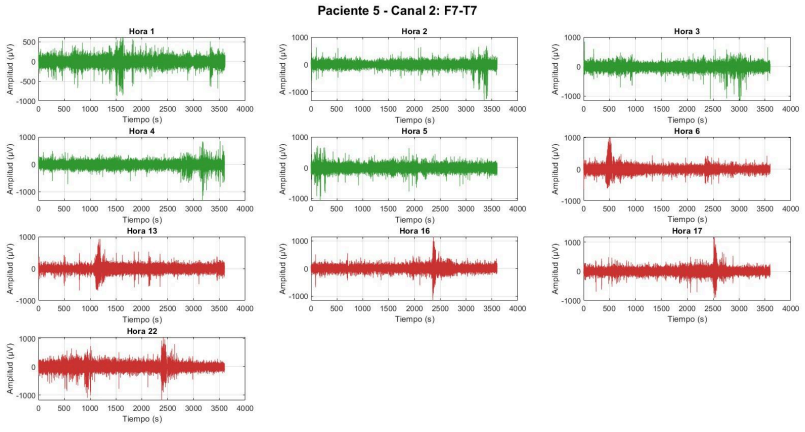
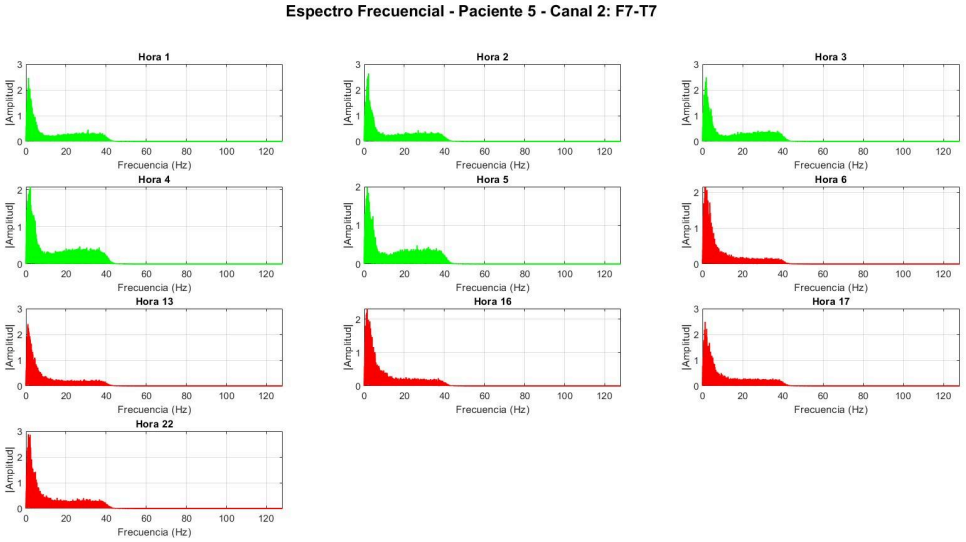


Figura 10. Representación espectral del electrodo F7-T7 para el paciente 5 filtrado



4. Propuestas de procesados

Como se ha mencionado anteriormente, se han desarrollado paralelamente dos métodos de procesado, ambos procedimientos utilizan un análisis estadístico. Mientras el primero se ha centrado en un análisis temporal, el segundo ha empleado un análisis frecuencial. Cabe mencionar que el segundo proceso se empleó como una primera aproximación, aunque no se consiguió resultados concluyentes. No obstante, se ha querido incluir con el objetivo de poner en valor el trabajo realizado.

4.1. Características temporales y umbrales adaptativos

Este sistema de extracción de crisis epilépticas, encontrado en el script ***main1.m***, se basa en los conocimientos clínicos de expertos para realizar un análisis temporal y se estructura en tres etapas principales: extracción de parámetros, detección unicanal mediante umbrales percentiles y fusión multicanal con ponderación basada en la relevancia clínica de los canales EEG. A continuación, se va describir detalladamente cada una de estas fases.

Primeramente, con la función ***extraer_parametros.m***, las señales de EEG filtradas se segmentan en ventanas temporales de duración fija, con un solapamiento definido entre ellas con el objetivo de poder analizar mejor la actividad cerebral de forma localizada en el tiempo. Para cada ventana, se extraen cinco parámetros estadísticos para caracterizar las anomalías de las crisis epilépticas:

- Energía: suma de los cuadrados de las muestras de la señal en la ventana.
- Varianza: media de dispersión que refleja cuánto varían las muestras respecto al valor medio.
- RMS: valor cuadrático medio de la señal, relacionado con su potencia media.
- Zero Crossings: número de pasos por cero, número de veces que la señal cambia de signo.
- ARV: valor medio rectificado es una medida de la energía promedio para detectar cambios bruscos en la amplitud.

Este último parámetro se ha tenido en cuenta, dado que en este artículo de detección de crisis epilépticas (Mora López-Tercero, 2013) se utilizó como umbral de detección con excelentes resultados.

Siguiendo la misma estructura de organización de los datos *(pX.hY.chZ)*, los resultados estadísticos obtenidos se guardan en una matriz *parametros* de tamaño 5 x N donde las filas son los valores promedios de cada parámetro extraído y las columnas corresponden a las ventanas temporales de cada señal.

A continuación, se procede a evaluar, para cada canal y ventana, si la actividad puede considerarse anómala o indicativa de una posible crisis. En la función ***deteccion_eventos.m*** se utilizan umbrales adaptativos basados en percentiles, definidos manualmente para cada parámetro, con el objetivo de poder personalizar cada umbral a cada paciente, ya que, se sabe que las crisis siguen un mismo patrón dentro de un mismo paciente, pero distinto entre pacientes. Mientras que la energía, la varianza, el RMS y el

ARV tienen que superar un percentil, el número de cruces por cero debe quedar fuera de un rango intermedio.

Después de haber realizado numerosas pruebas se ha llegado a la conclusión de que los porcentajes óptimos son los siguientes:

Energía: 88%	ARV: 85%
Varianza: 88%	Zero-crossing low: 10%
RMS: 84%	Zero-crossing high: 70%

Asimismo, se considera una ventana como anómala, es decir, con posible presencia de crisis, si al menos cuatro de los cinco parámetros cumplen su criterio propio. El resultado se almacena en un vector binario por canal *detecciones*, indicando presencia o ausencia de anomalías.

Una vez obtenidas las detecciones binarias por canal y por ventana de tiempo, se lleva a cabo una fusión multicanal con ponderación mediante la función ***detectar_crisis_multicanal_duracion_ponderada.m***.

En esta etapa, se prioriza aquellos canales más relevantes clínicamente y se minimiza el impacto de los canales ruidos según Shoeb (2009) . Es por ello que los canales se clasifican en tres categorías: canales relevantes, canales neutrales y canales ruidosos. Cada canal recibe un peso numérico en función de esta clasificación y se aplican a las salidas binarias de detección de eventos. Se ha aplicado el siguiente criterio: 1.5 para canales relevantes, 1 para canales neutrales y 0.5 para canales ruidosos.

Seguidamente, se calcula la suma ponderada de detecciones entre todos los canales y si la suma supera un umbral dinámico *(0.40)*, se considera que existe una activación multicanal coherente que posiblemente sea indicativo de una crisis epiléptica. Asimismo, se aplica un criterio de detección temporal, para eliminar falsas detecciones puntuales, solo se consideran como crisis los eventos cuya duración supere una duración mínima de 10 segundos. Este criterio de duración se escogió ya que se obtenía unos mejores resultados, aunque en el estudio base de los datos empleados (Shoeb, 2009) utilizaban 6 segundos.

Finalmente, se obtiene un resumen por cada paciente y hora denominado *crisis_detectadas*, siguiendo la misma estructura jerárquica empleada, donde se incluye el número total de crisis detectadas, el tiempo de inicio y fin de cada crisis en segundos y la duración total acumulada de cada una de ellas.

4.2. Características según bandas frecuenciales

En este proceso se utiliza un análisis frecuencial de las señales EEG con episodios epilépticos. Este proceso lo dividimos en cinco partes: pre-procesado de las señales, segmentación temporal de la señal, filtrado con discriminación frecuencial, extracción de características y detección de los episodios.

A continuación del preprocesado explicado previamente en el apartado de banco de filtros, segmentamos las señales de los archivos en tramos de 2 segundos para poder analizar la señal con esa precisión en etapas posteriores (utilizando la función **segmentar_senal.m**). Sobre estos segmentos se realizarán los siguientes pasos.

Después, se utiliza un banco de filtros para filtrar según las distintas bandas frecuenciales de la señal mediante **filtrar_senales_banco.m**. En nuestro caso, utilizamos un banco de cinco filtros para dividir la señal filtrada. Este recurso se usa con el fin de poder distinguir distintas propiedades en las bandas frecuenciales en los segmentos en los que la hemos segmentado.

Con toda esta información, pasamos a la extracción de características de cada señal, implementada mediante la función **crisis_segmentos.m**. La primera característica que extraemos es la energía de cada banda. Con esta energía, decidimos calcular el ratio de la energía de la primera banda (0.5 - 8 Hz aproximadamente) frente a la energía del resto de bandas, según la siguiente fórmula:

$$ratio = \frac{E_1}{E_2+E_3+E_4+E_5}$$

En un primer momento, pensamos que se vería una variación de este ratio según hubiera crisis epiléptica o no, pero eso no se apreciaba en la realidad. Por ello, realizamos un análisis estadístico de este ratio de energías, calculando la media y la varianza del conjunto de ratios en los segmentos de crisis y de no crisis.

En cuanto a los resultados obtenidos, podemos ver que la media de estos datos es muy similar para ambos conjuntos de segmentos (con crisis y sin crisis). Por otro lado, la varianza sí que varía de uno a otro, ya que en los segmentos de crisis la varianza es más que el doble de la varianza en los segmentos sin crisis.

Por esta razón, decidimos, para cada segmento, utilizar un conjunto de segmentos anteriores y posteriores y realizar la varianza de los ratios en ese tramo para determinar si se da una crisis epiléptica utilizando la función **clasificacion_segmentos.m**.

Con el objetivo de generar una estructura lógica que resuma la actividad significativa detectada a nivel multicanal, facilitando la identificación de eventos como posibles crisis epilépticas, se implementó la función denominada ***and_logico_canales.m***. En este caso se evalúa, para cada segmento y pacientes, cuántos canales han sido clasificados como positivos, y se considera dicho segmento como relevante si el número de canales activos supera un umbral predefinido.

5. Análisis de resultados

A la hora de analizar la eficacia en la detección de crisis epilépticas, se han diseñado dos funciones para automatizar el cálculo tanto de la sensibilidad como de la especificidad.

5.1. Métodos

Con el objetivo de evaluar el rendimiento del sistema de detección de crisis epilépticas, se han diseñado dos funciones, para analizar tanto la sensibilidad como la especificidad.

Con la función ***calcular_sensibilidad.m***, se puede estimar la sensibilidad del sistema a nivel de hora y a nivel de crisis individual. Esta métrica refleja la capacidad para detectar verdaderos episodios críticos cuando realmente ocurren.

- Sensibilidad global por hora (*sens_global_hora*): proporción de horas que contienen al menos una crisis real en las que el sistema detectó una o más crisis.

Se identifican todas las horas que contienen al menos una crisis real. Si el sistema realiza al menos una detección en esa, se considera como verdadero positivo. La sensibilidad se calcula como el cociente entre el número de horas con crisis detectadas correctamente y el total de horas con crisis reales.

- Sensibilidad por crisis (*sens_global_crisis*): cuantifica la cantidad de crisis que fueron correctamente detectadas, considerando una coincidencia temporal aceptable.

Para cada crisis anotada manualmente, se analiza si existe alguna detección automática que coincida temporalmente dentro del margen definido. Si al menos una detección se solapa con la crisis real, esta se contabiliza como un verdadero positivo por crisis. La métrica se obtiene como el número de crisis correctamente detectadas dividido entre el total de crisis reales.

Con el objetivo de analizar el rendimiento en la detección de eventos, estos dos métodos se han aplicado de forma individual obteniendo *sens_hora_individual* y *sens_crisis_individual*.

Para evaluar la especificidad, es decir, la proporción de verdaderos negativos frente al total de casos negativos predichos y reales se ha empleado la función ***calcular_especificidad.m***. Cabe mencionar que nos hemos centrado en la capacidad del sistema para no detectar eventos cuando no hay crisis. Es por ello que consideramos:

- TN (*True Negatives*): Segundos en los cuales no hay crisis y no se detecta crisis.
- FP(*False Positives*): Segundos en los cuales no hay crisis, pero se detecta una crisis.

La función toma como entrada las *crisis_anotadas*, estructura con la crisis reales, incluyendo sus tiempos de inicio y fin; las *crisis_detectadas* estructura con las crisis detectadas automáticamente por el sistemas, y las *duraciones*, registro con la duración total del registro de cada paciente y hora.

A nivel de procedimiento, se convierten tanto las crisis reales como las detectadas en vectores binarios por segundo, donde el valor 1 indica que hay crisis y el valor 0 en caso

contrario. Se recorren ambos vectores para identificar los verdaderos negativos (TN) y los falsos positivos (FP), siguiendo el criterio mencionado. Asimismo, se calcula la especificidad individualmente para cada paciente que almacena en *especificidad_individual* y finalmente, la *especificidad_global*.

5.2. Resultados obtenidos

Cabe mencionar que los datos utilizados están registrados con un EEG superficial, no intracraneal, por lo que a la hora de interpretar los resultados, puede verse influenciado por artefactos evitables en un EEG intracraneal. Por otro lado, el estudio realizado por Ali Shoeb (2009) señala que existe una superposición en los registros de EEG entre los estados de crisis y no crisis, lo que plantea un compromiso entre la sensibilidad y la especificidad del detector.

Debido a la carga computacional que supone procesar todas las señales, hemos cogido una muestra de 14 pacientes. Hemos descartado algunos pacientes porque presentaban una notación diferente a la que hemos empleado nosotros y otros debido a que los documentos de texto con las anotaciones estaban incompletos. Asimismo, no se han tenido en cuenta los pacientes con señales excesivamente ruidosas como son el paciente 13 y el 15, que en el propio estudio (Shoeb, 2009) ya estaban marcados como conflictivos. Teniendo esto en cuenta, el resto de las señales procesadas se han seleccionado de forma aleatoria.

Dado que los resultados del método 2 no fueron concluyentes, a continuación se presentarán solo los relacionados con el método 1 basado en umbrales adaptativos de características temporales.

Los resultados globales obtenidos de sensibilidad son los siguientes:

global_sens_crisis	0.8182	*global_sens_horas*	0.8475

Tabla 1. Resultado individuales de sensibilidad por solapamiento de crisis en el tiempo

Paciente 1	0.8571	Paciente 9	1
Paciente 2	1	Paciente 11	1
Paciente 3	0.5714	Paciente 18	0.5000
Paciente 4	0.7500	Paciente 19	1
Paciente 5	1	Paciente 20	0.5714
Paciente 7	1	Paciente 22	1
Paciente 8	0.8000	Paciente 23	1

Vamos a contrastar estos resultados con aquellos del estudio realizado por Shoeb (2009), donde se obtuvo una puntuación de 0.96. No obstante, hay que remarcar que en este artículo se hace uso de un clasificador para el entrenamiento de una red neuronal, lo cual no es comparable al método que hemos empleado

Asimismo, se ha obtenido una especificidad global de 0.9737. Esto significa que es bastante fiable a la hora de detectar si los pacientes no tienen crisis epilépticas. En el estudio original de Shoeb (2009), la tasa mediana de falsas detecciones es de 2 falsas detecciones por cada 24 horas.

Tabla 2. Resultado individuales de especificidad por solapamiento de crisis en el tiempo

Paciente 1	0.9912	Paciente 9	0.9327
Paciente 2	0.9519	Paciente 11	0.9904
Paciente 3	0.9762	Paciente 18	0.9796
Paciente 4	0.9699	Paciente 19	0.9749
Paciente 5	0.9705	Paciente 20	0.9870
Paciente 7	0.9735	Paciente 22	0.9805
Paciente 8	0.9783	Paciente 23	0.9902

6. Conclusiones

En primer lugar, nos hemos encontrado con dificultades para la lectura de los datos. Éstos se encuentran en registros de longitud variable (1h, 2h o 4h) según el paciente y en algunos casos el último registro es de menor longitud que el resto dentro de un mismo paciente. Asimismo, la variabilidad en la nomenclatura de la información en los archivos de texto con la información correspondiente a la localización temporal de los ataques epilépticos así como los cambios en la numeración de los canales del EEG entre pacientes e incluso dentro de uno mismo dificultan la extracción de los datos para su posterior uso.

Además, la variabilidad de las crisis epilépticas entre distintos pacientes dificultan su reconocimiento así como la generalización del método utilizado para el análisis. A esta dificultad se suma la interpretación de la señal EEG, no estacionaria y suma de varios procesos cognitivos. Por ello, es complicado aislar o localizar los momentos en los que se produce un suceso epiléptico.

En cuanto a las interferencias, el hecho de que varias de éstas se solapen en frecuencia con la señal dificulta o incluso imposibilita su eliminación. Asimismo, en alguna de las señales se pueden observar picos a 16 Hz entre otras frecuencias que podrían estar ligados a la interferencia de red. Estos picos podrían haber sido producidos debido al no uso, antes del muestreo, de un filtro anti-alias de orden suficiente, que no protegería frente a armónicos de la señal de 60 Hz de la red.

Otra dificultad encontrada es el hecho de que la mayoría de artículos que realizan un procesado de señales para detectar crisis epilépticas utilizan redes neuronales, por lo que la comparación directa con otros procedimientos más clásicos e interpretables se ve dificultada.

También cabe destacar los problemas relacionados con el coste computacional. Un ejemplo de éstos es el volumen de datos, contando con un alto número de registros de elevada longitud, lo cual supone un alto requisito de almacenamiento y un elevado tiempo de descarga. Por lo tanto, se ha optado por seleccionar ciertos registros de ciertos pacientes y minimizar el coste computacional del procesado reduciendo en la medida de lo posible el orden de los filtros. Por ello, se han utilizado filtros de orden 4.

Por otro lado, no se ha optado por la combinación de ambos métodos propuestos debido al tiempo disponible para la realización del proyecto así como por el elevado coste computacional que ello supondría. No obstante, para obtener resultados más precisos se podría probar combinar los criterios de las características temporales con las frecuenciales, buscando una relación lógica entre ellos que consiga mejorar la sensibilidad. También, podría resultar útil utilizar una red neuronal para la clasificación de los datos que permitiría el uso de clasificadores más eficientes, la automatización del proceso y un aprendizaje constante.

7. Bibliografía

- Shoeb, A. (2009). *Application of machine learning to epileptic seizure prediction* (Doctoral dissertation, Massachusetts Institute of Technology). MIT Libraries. https://dspace.mit.edu/handle/1721.1/54669
- Gauthier Umaña, C. (2005). Análisis de senales de electroencefalografia (EEG) para la deteccion temprana de crisis de epilepsia. Disponible en: https://repositorio.uniandes.edu.co/entities/publication/5984f48d-3771-4774-9982-61f83143524c
- Scharfman, H. E. (2007). The neurobiology of epilepsy. *Current Neurology and Neuroscience Reports, 7*(4), 348-354. https://doi.org/10.1007/s11910-007-0053-z
- López-Trigo, J., Blanco Hernández, T., & Ortiz Sánchez, P. (2011). Indicaciones del electroencefalograma en la epilepsia. *Programa de Formación Médica Continuada Acreditado*. Recuperado de https://www.academia.edu/109143395/Indicaciones_del_electroencefalograma_en_la_epilepsia
- Wilson, S., Scheuer, M., Emerson, R., and Gabor, A. Seizure detection: Evaluation of the Reveal algorithm. Clinical Neurophysiology, 10:2280–2291, Oct 2004.
- Hu, S., Zheng, G., & Peters, B. (2013). Driver fatigue detection from electroencephalogram spectrum after electrooculography artefact removal. IET Intelligent Transport Systems, 7(1), 105–113. https://doi.org/10.1049/iet-its.2012.0045
- Mora López-Tercero, I. (2013). Detección de crisis epilépticas a partir de señales EEG mediante índices basados en el algoritmo de Lempel-Ziv [Tesis de grado, Universitat Politècnica de Catalunya]. UPCommons. https://upcommons.upc.edu/handle/2099.1/19558
- Schiemann, J. and Salgado, I. (2000). *Trastornos del sueño*. Fagron. https://fagron.co/f1L35/PSIQUIATRIA/TRANSTORNOS_DEL_SUENO/Melatonina/Trastornos%20del%20suen%CC%83o%2C%20J.%20Schiemann%2C%20I.%20Salgado.pdf